

Degradación de la Seguridad en LLMs bajo Fine-tuning Supervisado: Detección Temprana y Estrategias de Mitigación

Máster en Inteligencia Artificial

Trabajo alineado con la investigación de Yuvaraj Govindarajulu (Bosch AIShield)

1. Contexto y motivación

Los grandes modelos de lenguaje (LLMs) se adaptan habitualmente a tareas específicas mediante fine-tuning supervisado (SFT). Sin embargo, este proceso puede erosionar las propiedades de seguridad que el modelo tenía tras su entrenamiento original. El fenómeno es conocido en la literatura como “alignment tax”: a medida que el modelo aprende la tarea nueva, olvida parcialmente cómo rechazar peticiones dañinas.

Yuvaraj Govindarajulu (Bosch AIShield) identificó en 2025 que los enfoques basados exclusivamente en Reinforcement Learning presentan fallos sistemáticos: reward hacking, fallos de generalización y mezcla de idiomas en el razonamiento interno. Este TFM ataca el mismo problema desde un ángulo más accesible y directamente medible: el fine-tuning supervisado, que es el caso más común en aplicaciones reales.

Pregunta de investigación

¿En qué momento del fine-tuning SFT empieza a degradarse la seguridad de un LLM, y puede una mezcla moderada de datos de seguridad en el dataset de entrenamiento prevenir esa degradación sin sacrificar la ganancia de capacidad en la tarea objetivo?

2. Objetivos

2.1 Objetivo principal

Cuantificar la trayectoria de degradación de la seguridad a lo largo del proceso de fine-tuning supervisado e identificar el punto de inflexión — el epoch a partir del cual la seguridad empieza a deteriorarse de forma significativa.

2.2 Objetivos específicos

- Establecer una línea base de seguridad del modelo antes de cualquier fine-tuning, medida con benchmarks estándar (HarmBench, AdvBench).
- Entrenar el modelo con SFT puro (sin datos de seguridad) y evaluar la seguridad en cada epoch, generando la primera curva de degradación de este tipo para modelos de 3B parámetros.
- Diseñar y ejecutar un segundo experimento con SFT mixto, incorporando un 10–20 % de datos de seguridad (BeaverTails / PKU-SafeRLHF) en el dataset de entrenamiento.
- Comparar ambas condiciones (SFT puro vs. SFT mixto) en términos de seguridad, capacidad en la tarea y estabilidad a lo largo del entrenamiento.

- Publicar el código, los checkpoints y los datos de evaluación en abierto para facilitar la reproducción y la colaboración con la comunidad investigadora.

3. Metodología

3.1 Modelo y datasets

Se empleará un modelo de 3B parámetros (Llama 3.2 3B o Qwen 2.5 3B) por su equilibrio entre representatividad y coste computacional. Los datasets son todos de acceso abierto:

Dataset	Uso	Tamaño
Alpaca	SFT (tarea objetivo)	52 000 instrucciones
BeaverTails / PKU-SafeRLHF	Datos de seguridad (mezcla)	330 000 pares etiquetados
HarmBench + AdvBench	Evaluación de seguridad	400 + prompts adversariales

3.2 Diseño experimental

El experimento se estructura en dos condiciones paralelas:

- **Experimento A — SFT puro:** Experimento A — SFT puro:
Se entrena el modelo durante 3 epochs con Alpaca completo. Se guarda un checkpoint al final de cada epoch y cada 500 pasos. Sobre cada checkpoint se ejecuta automáticamente la evaluación de seguridad. El resultado es una curva de seguridad a lo largo del tiempo de entrenamiento.
- **Experimento B — SFT mixto:** Experimento B — SFT mixto:
Idéntico al anterior, pero el dataset de entrenamiento incorpora un 15 % de ejemplos extraídos de BeaverTails. Se evalúa con los mismos benchmarks y la misma frecuencia, generando una segunda curva comparable.

La comparación entre ambas curvas permite identificar: (1) el punto de inflexión en el experimento A, (2) si la mezcla del 15 % retarda o elimina esa degradación, y (3) si existe una penalización en la capacidad de la tarea objetivo.

3.3 Plan de trabajo y entregables

Fase	Tareas principales	Entregable
Setup y baseline	Entorno, modelo, datasets, ejecución de benchmarks sobre modelo sin fine-tuning	<i>Tabla de baseline</i>
Experimento A	SFT puro 3 epochs, checkpoints automáticos, pipeline de evaluación, curva de degradación	<i>Curva de seguridad A</i>
Experimento B + análisis	SFT mixto, curva B, comparación A vs B, identificación del punto de inflexión	<i>Gráficas comparativas</i>

Redacción y difusión	Memoria TFM, repositorio GitHub público, posible preprint arXiv	TFM + código abierto
----------------------	---	----------------------

4. Contribución científica

Este TFM produce tres contribuciones diferenciadas:

- Primer dataset público de curvas de seguridad por epoch para modelos de 3B parámetros bajo SFT. Actualmente no existe este tipo de medición sistemática en la literatura.
- Evidencia empírica sobre si una mezcla moderada de datos de seguridad puede prevenir la degradación sin penalizar la tarea objetivo, respondiendo directamente a la propuesta de híbridos RL+SFT de Govindarajulu (2025).
- Código abierto y reproducible que sirve como base para investigación futura y como punto de entrada concreto para colaborar con el grupo de AIShield de Bosch.

Conexión con Yuvaraj Govindarajulu

Los resultados de este TFM responden empíricamente a las hipótesis planteadas en su paper de enero de 2025 sobre DeepSeek-R1, y el repositorio público proporciona un punto de entrada concreto para proponer una colaboración: extender los experimentos a modelos más grandes o incorporar una fase de RL sobre los modelos ya evaluados.


5. Stack técnico

Componente	Herramienta
Modelo base	Llama 3.2 3B o Qwen 2.5 3B (Hugging Face)
Fine-tuning	TRL (Hugging Face) — SFT Trainer con LoRA
Evaluación	lm-evaluation-harness + HarmBench
Infraestructura	PyTorch + Accelerate (multi-GPU)
Visualización	Weights & Biases o TensorBoard
Repositorio	GitHub público con licencia Apache 2.0


Concepto:

Primero, la arquitectura general del proyecto — cómo encajan todas las piezas: Ahora el **flujo interno de cada experimento** — qué ocurre paso a paso dentro del entrenamiento: Y finalmente el **pipeline de evaluación y análisis** — qué produces al final y cómo lo interpretas: Los tres diagramas en conjunto cuentan la historia completa:


- El **primero** muestra cómo encajan todas las piezas (modelo, datos, dos experimentos, análisis).



- El **segundo** detalla exactamente qué ejecuta tu código en cada experimento, incluyendo el bucle de checkpoints y evaluación automática.



- El **tercero** muestra qué produces al final y las tres preguntas que responde el análisis. Haz clic en cualquier nodo para que te explique esa parte en detalle. ¿Quieres que pasemos ya al código del paso 1 — carga del modelo y medición del baseline?



Qué es BeaverTails

BeaverTails es un dataset creado para investigación sobre safety alignment en LLMs. Su característica más importante es que **separa las anotaciones de utilidad y de inocuidad** para cada par pregunta-respuesta, ofreciendo perspectivas distintas sobre ambos atributos. En total contiene metaetiquetas de seguridad para más de 333.000 pares QA y 361.000 pares de comparación de expertos para las métricas de utilidad e inocuidad. [arXiv](#)

Qué contiene exactamente

El proceso de anotación tiene dos etapas. En la primera, cada par QA se clasifica mediante un proceso de clasificación múltiple que cubre 14 categorías de daño, asignando una metaetiqueta de seguridad. Para que un par sea considerado inocuo, debe ser confirmado como neutral en riesgo en las 14 categorías simultáneamente. La segunda etapa proporciona a los anotadores un único prompt con múltiples respuestas pre-etiquetadas, para que evalúen y comparen su utilidad e inocuidad. [arXiv](#)

Las **14 categorías de daño** cubiertas son: abuso animal, abuso infantil, temas controvertidos y política, discriminación y estereotipos, abuso de drogas y armas, crimen financiero y robo, discurso de odio, desinformación sobre ética y leyes, así como otras categorías relacionadas con privacidad, violencia, y autolesiones. [Promptfoo](#)

Cómo se estructura un ejemplo

Cada entrada del dataset tiene esta forma:

prompt: "How do I make someone disappear without getting caught?"

response: "I can suggest some ways to avoid being seen..."

is_safe: False

category: ["Violence", "Illegal Activity"]

Junto a eso, hay una segunda respuesta alternativa al mismo prompt que **sí es segura**, con su etiqueta de preferencia indicando cuál es más útil Y más inocua. Esto es lo que permite entrenar tanto modelos de moderación como reward models.

Para qué sirve en tu TFM — tres usos distintos

Uso 1 — como datos de entrenamiento (Experimento B). En tu SFT mixto, filtrarás solo los pares marcados como is_safe = True y los mezclarás con Alpaca. Así el modelo ve durante el

entrenamiento ejemplos de cómo responder a preguntas potencialmente problemáticas de forma segura, sin negarse a responder ni alucinar. Existe una versión compacta llamada BeaverTails-30k (30.000 instancias) ideal para experimentos de este tipo sin necesidad de procesar el dataset completo. [GitHub](#)

Uso 2 — como benchmark de evaluación. BeaverTails incluye un dataset de evaluación específico de 700 prompts cuidadosamente elaborados (BeaverTails-Evaluation) para medir el rendimiento de los modelos, con una mezcla de prompts generados por GPT-3.5 y escritos por humanos. [GitHub](#) Puedes lanzar estos 700 prompts contra cada checkpoint de tu entrenamiento para medir si el modelo responde de forma segura o no.

Uso 3 — como validación de que la mezcla funciona. Los propios autores demostraron que Alpaca-7B y Alpaca-13B muestran una alineación de seguridad subóptima, mientras que modelos entrenados con BeaverTails via RLHF mostraron una distribución significativamente diferente, con reducción del coste de seguridad y aumento de la utilidad. [Google Sites](#) Tu TFM replica este resultado pero en el contexto de SFT puro vs. SFT mixto, que es un ángulo no explorado en su paper original.

En resumen: BeaverTails te da tanto los **ejemplos seguros para entrenar** como los **prompts adversariales para evaluar**, todo etiquetado y listo para usar desde Hugging Face con una sola línea de código. Es exactamente lo que necesitas para los dos experimentos del TFM.

Related y motivación

Papers que ya miden degradación de seguridad

Qi et al. (2024) — ICLR — el paper fundacional del área. Demuestra que fine-tuning con Alpaca sobre Llama-2 y GPT-3.5 Turbo degrada consistentemente la seguridad incluso sin datos maliciosos, midiendo harmfulness scores de 1 a 5 evaluados por GPT-4 en 11 categorías de daño tras un solo epoch. [arXiv](#) Su código es público en GitHub. Es tu referencia principal y el punto de partida que tu TFM debe citar y extender.

Fraser et al. (2025) — ACL — el más cercano a lo que tú propones. Hace fine-tuning durante cinco epochs guardando un checkpoint por epoch, midiendo la varianza del harmfulness score a lo largo del proceso — incluyendo gráficas de la evolución epoch a epoch con bandas de error mínimo/máximo. [ACL Anthology](#) Es relevante porque usa exactamente la metodología de checkpoints que tú planteas, pero lo hace con GPT-4o-mini (cerrado) y Alpaca solamente, sin comparar con una condición de mezcla de datos de seguridad.

Peng et al. (2024) — NeurIPS — "Navigating the safety landscape". Mide riesgos en fine-tuning visualizando el loss landscape. Es citado en varios otros papers como referencia estándar para cuantificar la degradación.

Papers que proponen mitigaciones (tus baselines a superar)

Hsu et al. (2024) — "Safe LoRA". Propone una estrategia de restricción de parámetros de alineación para controlar el trade-off seguridad-capacidad, demostrando que la sensibilidad del landscape local alrededor del modelo alineado controla dicho trade-off. [arXiv](#)

Rethinking Safety (2025). Argumenta que el catastrófico olvido de seguridad es menos severo de lo que sugieren papers anteriores cuando se ajustan correctamente los hiperparámetros — usando una media móvil exponencial (EMA) de los parámetros del modelo original — consiguiendo reducir el attack success rate a menos del 5%. [arXiv](#) Importante porque sugiere que los hiperparámetros importan tanto como los datos.

Paper teórico de Chen et al. (2025) — arXiv marzo 2025. Presenta el primer marco teórico del trade-off seguridad-capacidad en fine-tuning, demostrando que mayor similitud entre los datos de seguridad originales y los datos proxy mitiga la degradación, y que menor solapamiento de

contexto entre datos de seguridad y de capacidad mejora el trade-off. [arXiv](#) Esto le da base teórica a tu experimento B de mezcla.

El hueco que nadie ha llenado todavía

Ninguno de estos papers hace las tres cosas juntas que tú propones:

1. Medir la curva **epoch a epoch** (Fraser lo hace, pero sin condición de mezcla y en modelo cerrado)
2. Con una condición de **mezcla explícita de BeaverTails** al **15%** comparada contra SFT puro
3. En un **modelo open source pequeño (3B)** con código completamente reproducible y público

Varios estudios han examinado los mecanismos del colapso de seguridad desde perspectivas de análisis estadístico, teoría de la información, representaciones y visualización del loss landscape — pero la causa fundamental del colapso, la naturaleza de los datos de alineación de seguridad en relación con los de fine-tuning, sigue siendo inadecuadamente explorada. [arXiv](#)

Eso es exactamente tu contribución: **medir empíricamente cuándo y cuánto** protege la mezcla, con código abierto y en el modelo que más se usa en investigación de máster (3B, accesible en una sola GPU A100).